

1. 基础信息

项目名称:用户购买行为预测 (User Behavior Buy Prediction)

任务类型:二分类任务 (Binary Classification)

模型名称:XGBoost (Version 3.2.0)

项目目标:基于用户历史行为数据, 预测用户未来是否会发生购买行为, 从而为推荐系统、精准营销及用户运营提供支持。

2. 数据集描述

数据来源:原始数据记录用户的浏览 (pv)、收藏 (fav)、加购 (cart) 和购买 (buy) 行为, 通过构建样本和标签, 将问题转化为二分类任务。

输入特征:围绕用户、商品、品类及交互行为构建统计特征, 包括:

- User 特征;
- Item 特征;
- Category 特征;
- User-Item 特征;
- User-Category 特征;
- Time特征;
- User-Time 特征;
- Item-Time特征;
- Category-Time特征;
- Time Gap 特征。

初始共构建 68 个特征。通过相关性分析删除高度相关特征后, 最终保留 53 个特征用于模型训练。

数据集划分: 按照时间顺序划分训练集、验证集和测试集, 以避免未来信息泄露 (Data Leakage)。

数据集	样本数量	占比
Train	8,579,834	70%
Validation	2,451,381	20%
Test	1,225,691	10%

总样本量为 : 12,256,906。

标签分布：
正样本比例约为 :1.43%，负样本比例约为 :98.57%，数据存在明显类别不平衡问题。

模型稳定性分析:特征筛选前后模型性能变化较小，说明模型在降低复杂度的同时保持了预测能力，具有较好的稳定性

3. 评估指标

由于数据类别极不平衡，仅使用 Accuracy 无法全面反映模型性能，因此采用以下指标：

- Accuracy
- Precision
- Recall
- F1 Score
- ROC AUC
- PR AUC

其中, PR AUC 能够更真实反映模型在少数类样本上的排序能力，因此将其作为模型选择和参数调优的主要评价指标。

最终模型结果

指标	数值
Accuracy	0.700
Precision	0.032
Recall	0.688
F1-score	0.062
ROC AUC	0.759
PR AUC	0.051

4. 模型性能分析与讨论

(1)模型构建

由于全量数据规模超过 1200 万条样本，为提高实验效率，在模型开发阶段首先采用抽样数据进行实验。

首先分别构建 Logistic Regression 和 XGBoost Baseline 模型, 对模型性能进行初步评估。

在 Baseline 基础上, 进一步分别对两个模型进行参数调优:

Logistic Regression

主要调整: 正则化参数 C

XGBoost

主要调整:

- n_estimators
- max_depth
- learning_rate

模型均在训练集上训练, 并在验证集上进行评估。

由于数据存在明显类别不平衡问题, 因此采用 **PR AUC** 作为模型选择依据。

实验结果表明, Logistic Regression 在不同参数下性能提升有限, 而 XGBoost 在 ROC AUC 和 PR AUC 指标上表现更优, 因此最终选择 XGBoost 作为最终模型。

(2) 参数调优

最终选择的 XGBoost 参数为:

- n_estimators = 300
- max_depth = 5
- learning_rate = 0.05

同时根据正负样本比例设置: $\text{scale_pos_weight} = \text{negative_count} / \text{positive_count}$ 以缓解类别不平衡问题。

确定最优参数后, 将 Train 和 Validation 数据集合并形成 Train + Validation 数据集(11,031,215 条样本), 并在全量数据上重新训练最终模型。最后在独立 Test 集上进行模型评估。

(3) 特征相关性分析

通过计算相关系数矩阵, 以0.95作为阈值识别高度相关特征。一共删除15个特征, 特征数量由68个减少为53个。


特征筛选前后模型性能对比如下:

指标	68个特征模型	53个特征模型
Accuracy	0.700	0.700
Precision	0.032	0.032
Recall	0.691	0.688
F1 Score	0.062	0.062
ROC AUC	0.760	0.759
PR AUC	0.050	0.051

结果表明，在减少约 22% 特征数量的情况下，模型性能基本保持稳定。


(4) ROC Curve分析

利用模型输出概率绘制ROC曲线，最终ROC AUC = 0.759，说明模型能够较好地地区分购买用户与非购买用户，具有较好的排序能力。



(5) PR Curve分析


由于正样本比例仅约为 1.43%，PR Curve 能够更加真实地反映模型在不平衡数据上的表现。最终PR AUC = 0.0505，明显高于随机预测器对应的正样本比例水平。因此，在本项目中采用 PR AUC 作为主要评价指标。



(6) Thershold调优分析

基于模型输出概率, 对不同 Threshold (0.3~0.9) 进行了实验。结果表明: 随着 Threshold 增大: Precision 逐渐提高, Recall 逐渐降低。

当 Threshold = 0.8 时, F1 Score 达到最高。但由于模型优化目标为 PR AUC, 而 PR AUC 与分类阈值无关, 因此最终模型仍采用默认 Threshold = 0.5。Threshold 调优结果可作为后续业务部署阶段 Precision 与 Recall 权衡的参考。



(7) 特征重要性分析


利用 XGBoost 输出 Feature Importance。

Top Feature 包括:

- ui_last_action_gap_hour
- ui_has_cart_7d
- ui_cart_rate_7d

- cate_buy_rate_7d
- ui_pv_cnt_7d
- current_behavior_type
- user_buy_rate_7d

结果表明:用户最近一次交互时间、加购行为以及历史转化率等特征, 对未来购买行为具有较强影响。



(8) 误差分析

根据混淆矩阵结果:

	Pred = 0	Pred = 1
Actual = 0	845,893	362,237
Actual = 1	5,475	12,086

模型能够识别大部分正样本, Recall 达到 68.82%。但由于类别极度不平衡, 同时产生较多假阳性样本, 导致 Precision 较低。这体现了 Precision 与 Recall 之间的权衡关系。

5. 环境与部署考量

推理速度: XGBoost 模型推理速度较快, 能够满足大规模用户行为预测需求。

模型大小: 模型规模较小, 占用磁盘空间有限, 便于保存和部署。

资源消耗: 模型训练主要依赖 CPU 资源, 在普通机器环境下即可完成训练和预测, 无需额外 GPU 支持。

6. 总结

本项目完成了从数据处理、特征工程、模型训练、参数调优、特征筛选到模型评估的完整机器学习流程。

主要成果包括:

- 构建 68 个行为特征;
- 通过相关性分析删除 15 个冗余特征, 最终保留 53 个特征;
- 建立 XGBoost 模型;
- 获得 ROC AUC = 0.7586;
- 获得 PR AUC = 0.0505;
- 完成 ROC Curve、PR Curve、Threshold 调优以及 Feature Importance 分析;
- 模型性能稳定, 具有较好的排序能力和可解释性。